

1. Projekt - Osnove podatkovne znanosti

Odabrani podatkovni skup je generiran uz pomoć umjetne inteligencije i nema pripadajući link. Prikazuje podatke o bossevima u popularnoj igri Elden Ring. Sastoji se od 120 redaka i 10 stupaca.

Rad sa bibliotekama

Uvoz potrebnih biblioteka:

1. pandas - biblioteka koju koristim za rad s tabličnim podacima; omogućava mi jednostavnu manipulaciju podacima iz mog data seta
2. matplotlib - biblioteka koja mi omogućava vizualizaciju podataka
3. seaborn - biblioteka koja mi također omogućava vizualizaciju podataka, temelji se na matplotlib-u
4. numpy - biblioteka koja mi olakšava rad sa nizevima brojeva i matricama; brze matematičke operacije

```
In [7]: import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns
import numpy as np
```

Uvoz podataka

Uvoz csv filea u Google Colab te uvoz lokalno pohranjenih podataka:

```
In [3]: from google.colab import files
fileovi = files.upload()
```

Choose Files

No file chosen

Upload widget is only available

when the cell has been executed in the current browser session. Please rerun this cell to enable.

Saving elden_ring_data.csv to elden_ring_data.csv

```
In [8]: df = pd.read_csv("elden_ring_data.csv")
```

Pregled podataka

.shape nam vraća dimenziju podatkovnog skupa (data framea) u formatu (broj redaka, broj stupaca)

```
In [28]: df.shape
```

Out[28]: (120, 10)

.info nam daje vizualni prikaz tablice te sažetak cijelog podatkovnog skupa:

1. RangeIndex (entries) govori koliko vrijednosti imamo u podatkovnom skupu
2. Data columns govori koliko je stupaca u skupu
3. Non-null count pokazuje ima li vrijednosti koje su "null", "0"...
4. dtypes govori i broji koje tipove podataka imamo u podatkovnom skupu

```
In [29]: print("Informacije o podatkovnom skupu:\n")
df.info()
```

Informacije o podatkovnom skupu:

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 120 entries, 0 to 119
Data columns (total 10 columns):
#   Column                Non-Null Count  Dtype
---  -
0   id                    120 non-null   int64
1   type                  120 non-null   object
2   full_name             120 non-null   object
3   region                120 non-null   object
4   progression_stage      120 non-null   object
5   lore_difficulty_rating 120 non-null   int64
6   phase_count           120 non-null   int64
7   mandatory_fight       120 non-null   bool
8   arena_openness        120 non-null   object
9   story_importance      120 non-null   int64
dtypes: bool(1), int64(4), object(5)
memory usage: 8.7+ KB
```

.head nam prikazuje prvih n redaka tablice

Defaultni prikaz je prvih pet redaka, ali vrijednosti mogu biti bilo koje (npr. df.head(10), df.head(20)...)

```
In [75]: print("Pregled podataka kojima raspolazemo:\n")
print(df.head(10))
```

Pregled podataka kojima raspolazemo:

	id	type	region \	full_name
0	1	Boss	Margit, the Fell Omen Limgrave	
1	2	Boss	Godrick the Grafted Limgrave	
2	3	Boss	Rennala, Queen of the Full Moon Lakes	Liurnia of the
3	4	Boss	Starscourge Radahn Caelid	
4	5	Boss	Rykard, Lord of Blasphemy Gelmir	Mt.
5	6	Boss	Morgott, the Omen King Capital	Leyndell, Royal
6	7	Boss	Fire Giant Giants	Mountaintops of the
7	8	Boss	Mohg, the Omen Sewers	Leyndell
8	9	Boss	Mohg, Lord of Blood Palace	Mohgwyn
9	10	Boss	Commander Niall Giants	Mountaintops of the

	progression_stage	lore_difficulty_rating	phase_count
0	early	3	2
1	early	3	2
2	mid	2	2
3	mid	4	2
4	mid	3	2
5	late	4	2
6	late	4	2
7	mid	3	2
8	late	4	2
9	late	4	2

	arena_openness	story_importance
0	semi-open	4
1	closed	4
2	closed	4
3	vast	5

4	closed	4
5	closed	5
6	vast	5
7	closed	3
8	closed	5
9	closed	4

.describe prikazuje deskriptivne statistike za stupce gdje se nalaze numeričke vrijednosti:

1. count - broji non-empty vrijednosti
2. mean - računa prosječnu vrijednost
3. 25%/50%/75% - percentili - izračunava koliko vrijednosti se nalazi ispod te granice
4. max - pronalazi maksimalnu vrijednost uzorka

```
In [78]: print("Kratki pregled podataka:\n")
print(df.describe())
```

Kratki pregled podataka:

	id	lore_difficulty_rating	phase_count
story_importance			
count	120.000000	120.000000	120.000000
mean	60.500000	3.041667	1.525000
std	34.785054	0.844118	0.501468
min	1.000000	2.000000	1.000000
25%	30.750000	2.000000	1.000000
50%	60.500000	3.000000	2.000000
75%	90.250000	4.000000	2.000000
max	120.000000	5.000000	2.000000

Provjera nedostajućih vrijednosti

.isna provjerava ima li nedostajućih vrijednosti u podatkovnom skupu

```
In [ ]: print(df.isna().sum())
```

```
id                0
type              0
full_name         0
region            0
progression_stage 0
lore_difficulty_rating 0
phase_count       0
mandatory_fight   0
arena_openness    0
story_importance  0
dtype: int64
```

Korištenje listi, riječnika, grananja i petlji

Ovdje sam koristila listu da bi pronašla jedinstvene regije na mapi Elden ringa:

```
In [30]: regije = df["region"].unique().tolist()
print("Nakon filtriranja podatkovnog skupa, lista jedinstvenih regija na
mapi je:\n", regije)
```

```
Nakon filtriranja podatkovnog skupa, lista jedinstvenih regija na
mapi je:
['Limgrave', 'Liurnia of the Lakes', 'Caelid', 'Mt. Gelmir',
'Leyndell, Royal Capital', 'Mountaintops of the Giants', 'Leyndell
Sewers', 'Mohgwyn Palace', "Miquella's Haligtree", 'Erdtree',
'Altus Plateau']
```

Ovdje sam primjenila riječnik kako bi prikazala koliko ima main bosseva, a koliko mini bosseva u igri:

```
In [31]: brojacBosseva = df["type"].value_counts().to_dict()
print("Zapisano u obliku rijecnika, bossevi su raspoređeni:\n",
brojacBosseva)
```

```
Zapisano u obliku rijecnika, bossevi su raspoređeni:
{'Mini-Boss': 107, 'Boss': 13}
```

Ovdje sam također iskoristila riječnik, ali da bi prikazala koliko bosseva ima u svakoj regiji na mapi:

```
In [32]: brojacPoRegiji = df["region"].value_counts().to_dict()
print("Zapisano u obliku rijecnika, broj bosseva po regijama je:\n",
brojacPoRegiji)
```

```
Zapisano u obliku rijecnika, broj bosseva po regijama je:
{'Limgrave': 24, 'Liurnia of the Lakes': 23, 'Mountaintops of the
Giants': 23, 'Caelid': 22, 'Altus Plateau': 21, 'Erdtree': 2, 'Mt.
Gelmir': 1, 'Leyndell Sewers': 1, 'Leyndell, Royal Capital': 1,
"Miquella's Haligtree": 1, 'Mohgwyn Palace': 1}
```

Ovdje sam napravila loop u koji korisnik unosi svoj progression stage te mu ispisuje gdje trenutno nalazi u igri:

```
In [27]: for unosProg in df['progression_stage']:
unosProg = input("Unesi u kojem si progression stageu (early, mid,
late, endgame): ")

if unosProg == "early":
    print("Tek si na pocetku, nastavi igrati Tarnished!")
    break
elif unosProg == "mid":
    print("Na pola si puta!")
    break
elif unosProg == "late":
    print("Skoro si na kraju Tarnished!")
    break
elif unosProg == "endgame":
    print("Tvoja prica dolazi kraju, sada si Elden Lord!")
    break
```

```
Unesi u kojem si progression stageu (early, mid, late, endgame):
endgame
Tvoja prica dolazi kraju, sada si Elden Lord!
```

Filtriranje i sortiranje podataka

.sort_values nam omogućava sortiranje podatkovnog skupa

- *ascending* = *True* - sortira uzlazno (od najmanjeg do najvećeg)

- *ascending* = *False* - sortira silazno (od najvećeg do najmanjeg)

```
In [76]: diffSort = df.sort_values(by = "lore_difficulty_rating", ascending =
False)
print("Top 5 najtežih bosseva u igri:\n", diffSort.head())
```

Top 5 najtežih bosseva u igri:

	id	type	full_name	region
\				
12	13	Boss	Elden Beast	Erdtree
10	11	Boss	Malenia, Blade of Miquella	Miquella's Haligtree
3	4	Boss	Starscourge Radahn	Caelid
5	6	Boss	Morgott, the Omen King	Leyndell, Royal Capital
8	9	Boss	Mohg, Lord of Blood	Mohgwyn Palace

	progression_stage	lore_difficulty_rating	phase_count
mandatory_fight	\		
12	endgame	5	1
True			
10	endgame	5	2
True			
3	mid	4	2
True			
5	late	4	2
True			
8	late	4	2
True			

	arena_openness	story_importance
12	vast	5
10	open	5
3	vast	5
5	closed	5
8	closed	5

Ovdje sam koristila filter da bih prikazala točno koji bossevi se nalaze u određenoj regiji:


```
In [77]: filterCaelid = df[df["region"] == "Caelid"]
print("Bossevi koji se nalaze u regiji Caelid su:\n",
      filterCaelid.head())
```

```
Bossevi koji se nalaze u regiji Caelid su:
      id      type      full_name  region
\
3      4      Boss      Starscourge Radahn  Caelid
15 16 Mini-Boss  Erdtree Avatar (Black Knife Catacombs)  Caelid
20 21 Mini-Boss      Putrid Avatar (Zamor Ruins)  Caelid
25 26 Mini-Boss      Tree Sentinel (Unsightly Catacombs)  Caelid
30 31 Mini-Boss  Perfumer Tricia (Auriza Hero'S Grave)  Caelid

      progression_stage  lore_difficulty_rating  phase_count
mandatory_fight  \
3      mid      4      2
True
15      late      2      2
False
20      late      2      1
False
25      endgame      3      1
False
30      late      2      1
False

      arena_openness  story_importance
3      vast      5
15      closed      2
20      semi-open      2
25      vast      2
30      open      2
```

Funkcije

Ovdje sam napravila **funkciju** koja računa prosječnu vrijednost varijable `phase_count` (koliko faza ima boss, tj. postane li jači u jednom trenutku borbe) za glavne bosseve i mini bosseve te koristeci `.round()` sam zaokružila na najbliži cijeli broj:

```
In [35]: def izracunProsjecnihBossPhaseova(bossPhase):
      return df[df['type'] == bossPhase]['phase_count'].mean()

avgPhMB = izracunProsjecnihBossPhaseova("Mini-Boss").round()
avgPhB = izracunProsjecnihBossPhaseova("Boss").round()
print(f"Prosjecan broj boss phaseova za main bosseve je: {avgPhB}, a za
      mini bosseve je: {avgPhMB}")
```

```
Prosjecan broj boss phaseova za main bosseve je: 2.0, a za mini
bosseve je: 1.0
```

Funkcija za provjeru je li unešeni boss obavezan za daljni progress u igri:

Prvo sam potrebne stupce stavila u liste te sam kroz funkciju preko indexa unešenog bossa tražila isti index u listi za mandatory fight za provjeru True ili False te ovisno o vrijednosti ispisala:

```
In [23]: boss_imena = list(df["full_name"])
mandatory_lista = list(df["mandatory_fight"])

def mandatory_boss():
    ime = input("Unesi ime bossa: ")
    if mandatory_lista[boss_imena.index(ime)]:
        print("Boss JE mandatory fight.")
    else:
        print("Boss NIJE mandatory fight.")

mandatory_boss()
```


```
Unesi ime bossa: Malenia, Blade of Miquella
Boss JE mandatory fight.
```

Vizualizacije podataka

Countplot kreira **stupičasti grafikon** te je idealan za prikazivanje *kategorijskih podataka*

Ja sam ga koristila da bi prikazala glavne i mini bosseve u odnosu na otvorenost njihove arene (prostor gdje se borimo sa njima)


```
In [47]: sns.countplot(data=df, x="arena_openness", hue = "type", palette =
"pastel")
plt.title("Broj bosseva i otvorenost arene")
plt.xlabel("Vrsta arene")
plt.ylabel("Broj bosseva")
plt.legend(title = "Vrsta", loc = "upper right")
plt.show()
```



Seaborn graf **barplot** uzima neku kategoričku vrijednost za x os i neku numeričku vrijednost za y os te prikazuje *prosječnu vrijednost po kategoriji*

Ja sam ga ovdje koristila da prikážem težinu bosseva ovisno o tome je li glavni ili mini boss

```
In [65]: sns.barplot(data = df, x = "type", y = "lore_difficulty_rating", color =
"salmon")
plt.xlabel("Vrsta bosseva")
plt.ylabel("Težina bosseva")
plt.title("Prosječna težina bosseva")
plt.show()
```




Pie chart grafički prikazuje podatke u obliku kruga ili "torte" gdje svaki segment prikazuje *udio određene kategorije u cjelini*

Ja sam ga koristila da bi prikazala udio bosseva ovisno u kojem dijelu igre se nalazimo

```
In [71]: df["progression_stage"].value_counts().plot.pie(autopct = "%1.1f%%",
startangle = 90, colors = sns.color_palette("pastel"))
plt.title("Udio bosseva po progression stageu")
plt.ylabel("")
plt.show()
```

Udio bosseva po progression stageu



Histogram koristimo za grafički prikaz numeričkih podataka i njim prikazujemo učestalost podataka (y os) u određenim intervalima, tj. bins (x os)

Distribucija podataka može biti:

1. simetrična (podaci su ravnomjerno raspoređeni)
2. pozitivno skewed (podaci se "naginju" na lijevu stranu)
3. negativno skewed (podaci se "naginju" na desnu stranu)

Ja sam ga koristila da bih prikazala distribuciju težine bosseva i u mom slučaju distribucija podataka je pozitivno skewed

```
In [74]: sns.histplot(data=df, x="lore_difficulty_rating", bins=5, color =  
          "lightpink", edgecolor = "purple")  
plt.title("Distribucija težine bosseva")  
plt.xlabel("Težina bosseva")  
plt.ylabel("Broj bosseva")  
plt.show()
```

